机器学习测试题（样例）

一、简要回答以下问题（20 分，每小问 5 分）

1. 如何定义回归模型的泛化误差，请给出三种方法可以提升模型的泛化能力。
2. 设一个统计模型 $Y = f(X) + \varepsilon$ 的自变量 $X \in R^{10}$，如果用线性函数族 $\left\{ y = \alpha_0 + \sum_{i=1}^{q} \beta_i x_i \right\}$ 来回归，当增加自变量维数 q，回归函数的方差会减少吗？
3. 计算一个线性函数族 $\left\{ f(\mathbf{x}, \beta) = \beta_0 + \sum_{i=1}^{p} \beta_i x_i, \mathbf{x} \in R^p \right\}$ 的 Vapnik-Chervonenkis（VC）维数，简要说明理由。
4. 当 LASSO 回归的代价函数中 $RSS(\lambda) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda \|\beta\|_1$ 的参数 λ 增加时，讨论 Lasso 回归的解向量 β 的非零分量个数变化规律。

二、(15 分) 考虑训练数据 $\{(x_i, y_i)\}_{i=1}^{N}$ 上的 KNN 回归问题，$N(x_0)$ 是预测点 x_0 的 k 个最近邻的样本点集合。KNN 预测模型为

$$\hat{f}(x_0) = \frac{1}{k} \sum_{x_j \in N(x_0)} y_j \ .$$

1. 请推导 KNN 模型方差表达式 $\mathrm{var}[\hat{f}(x_0)] = \sigma_\varepsilon^2 / k.$
2. 请解释为什么 k-最近邻方法(K-NN)不适合用于高维回归预测问题。

三、（15 分） 设 $\{(x_i, y_i)\}_{i=1}^{N}$ 是训练数据，$x_i \in R^p$。证明估计的线性回归函数 $\hat{f}(x_0) = \beta_0 + \beta^T x_0 = \bar{x}_0^T \bar{\beta}, \text{where } \bar{x}_0 = (1, x_0^T)^T$ 可以写成以下形式：

$$\hat{f}(x_0) = \sum_{i=1}^{N} l_i(x_0, X) y_i \ ,$$

其中 $\{l_i(x_0, X)\}_{i=1}^{N}$ 不依赖于 $\{y_i\}_{i=1}^{N}$，$X = (\bar{x}_1, \bar{x}_2, \cdots, \bar{x}_N)^T$ 表示数据矩阵。

1. 请推导 $l_i(x_0, X)$ 的详细表达式。
2. 并计算预测模型 $\hat{f}(x_0)$ 的方差（用 $\{l_i(x_0, X)\}_{i=1}^{N}$ 表示）。

四、(15 分) 设训练数据 $\{(x_i, y_i)\}_{i=1}^{N}$，其中 $x_i \in R^n, y_i \in \{-1, 1\}$，是线性可分的。

1. 请给出分界面间隔 $(w^T x + b = \pm 1)$ 极大的约束优化问题数学表述，并利用 Lagrange 乘子法将给问题转化为二次规划问题；

2. 什么是支持向量？给出计算分界面的常数项 b 的计算公式；

3. 对于非线性可分问题，给出改进的处理方法；

五、(15 分) 设 $p(y\,|\,x,\beta)\ \sim N(\beta_0+x^T\beta,\sigma^2)$，且参数 $\beta_i\sim N(0,\tau^2),\ i=1,\cdots,p$ 相互独立。给出参数 β 的后验概率 $f\left(\beta\,|\,x,y\right)$ 计算表达式。如果 σ^2 和 τ^2 已知，证明极大对数后验概率 $f\left(\beta\,|\,x,y\right)$ 等价于线性岭回归估计，并给出岭回归正则化参数 λ 与方差 σ^2 和 τ^2 之间的关系。

六、(20 分) 考虑统计模型 $Y=f(X)+\varepsilon$，其中 $\varepsilon\sim N(0,\sigma_\varepsilon^2)$. 给定训练数据 $\left\{\left(x_i,y_i\right)\right\}_{i=1}^N$, $x_i\in R^p, y_i\in R^1$. 记 $\hat{y}=\hat{f}(X)$ 是回归函数。定义样本点内误差

$$Err_{in}=\frac{1}{N}\sum_{i=1}^{N}E_{Y^{new}}\left[L(Y_i^{new},\hat{f}(x_i))|\mathrm{T}\right],$$

1. 如果损失函数是均方误差，证明其乐观性值（Optimism）表示为

$$op=E_{\mathrm{y}}\left[Err_{in}-\overline{err}\right]=\frac{2}{N}\sum_{i=1}^{N}Cov(\hat{y}_i,y_i),$$

其中 $\hat{y}_i=\hat{f}(x_i)$, $\overline{\mathrm{err}}$ 是训练误差。

2. 对于线性预测模型 $f(x)=\beta_0+\beta^Tx=\bar{x}^T\overline{\beta},\bar{x}=(1,x^T)^T\in R^{p+1}$, 证明以下关系

$$\sum_{i=1}^{N}Cov(\hat{y}_i,y_i)=(p+1)\sigma_\varepsilon^2.$$