CS3339 机器学习 2025 年秋季项目

1 引言

在这个项目中，你需要使用高维特征数据完成一个分类任务。这些数据来自一个匿名的图像分类数据集，其中每张图像都被归类到 100 个预定义类别中的一个。由于我们的课程重点是统计学习，而非从原始数据中提取特征，因此我们会提供从该数据集中预先提取的特征，而非原始图像。

训练集共有 19573 张图像，我们还有 10000 张图像用于测试。每张图像都被表示为一个 512 维向量。你可以直接将这些特征及其对应的标签作为 csv 文件加载。你可以自行按理想的比例划分验证数据集。
你的目标是使用我们提供的数据训练统计学习模型，并尽可能达到高的测试准确率。具体说明如下。

2 要求

在本项目中，你应该：

- 尝试至少三种不同的统计学习方法，其中至少两种不是深度学习。我们推荐本课程中学习过的方法。
- 使用至少两种模型评估和选择方法来选择最佳模型，并增强模型的稳健性和泛化能力。
- 按照第 3 节中的说明提交一份报告、你的代码以及测试数据集上的结果。

在完成这项任务时，你可能需要执行以下操作：

- 探索性数据分析，包括：
  - 理解特征空间和类别分布，
  - 分析数据的稀疏性及其影响；

- 隆维（包括：
  - 应用诸如主成分分析（PCA）或奇异值分解（SVD）之类的技术。
  - 讨论其对模型性能和可解释性的影响；
- 模型开发（包括：
  - 采用各种统计学习模型（例如，逻辑回归、线性支持向量机），
  - 尝试不同的正则化技术来处理过拟合问题；
- 模型评估：执行交叉验证以评估模型的泛化能力。

请注意，尽管测试准确率（及其排名）是你成绩的一部分，但它并非唯一的组成部分。详细的分析、大量的实验、清晰且撰写良好的报告、基于基础库（例如 numpy）手动实现算法、对标准算法进行合理修改以及其他亮点，这些都会有助于你完成一个高分的优秀项目。你或许不希望陷入对性能和排名的微小改进中。

3 次提交

你应该通过 Canvas 提交报告和代码，并通过 Kaggle 平台提交测试数据集上的结果。报告和代码应打包成一个压缩文件，以你的学号和姓名命名，结构如下：

3.1 报告

你的报告应描述你是如何完成这个项目的，其中可能包括：

- 数据处理技术以及选择这些技术的原因；
- 所用模型的简要介绍；
- 所使用的模型评估和模型选择方法，以及如何处理数据的稀疏性和高维度；
- 你如何评估自己的模型；
- 结论；
- 你想在本项目中报告的任何其他内容。

报告应以 PDF 文件形式提交，建议篇幅不少于 6 页。我们建议使用顶级会议和期刊提供的 LATEX 模板。

3.2 代码

您的代码将用于检查可复现性。因此，您的代码应包含一个 Readme 文件，说明如何复现您在 kaggle 上提交并在报告中提及的结果。对于简单情况，可以是一个 txt 文件；如果情况复杂，建议使用 PDF 文件。

3.3 测试结果

https://www.kaggle.com/t/95bbe89d4bed41ecb2985cb25b93394f

你需要在这场 Kaggle 竞赛中提交你的测试结果。你应该在提交截止日期前提交结果。你还需要在报告中包含所用方法准确性的截图。

4 截止日期

Kaggle 和 Canvas 提交截止日期：2026 年 1 月 11 日。